


# Akustička detekcija anomalija na ESP32-S3

Pregled projekta master rada

## 1. Cilj, hardver i eksperimentalna postavka

Projekat se bavi detekcijom promjena u zvuku ventilatora. Obrada signala i donošenje odluke izvršavaju se na mikrokontroleru ESP32-S3. Poslije kalibracije na normalnom radu, sistem aktivira alarm kada registruje odstupanje kroz više uzastopnih intervala.

Hardver čine ESP32-S3, mikrofoni INMP441 povezan preko I2S veze, taster i mjerna ploča sa INA226. Probe su izvedene u sobi, sa mikrofonom na 40 cm od ventilatora i USB napajanjem od 5 V. Računar vodi probu i bilježi rezultate, a obrada zvuka i odluka izvršavaju se na uređaju.



Slika 1. Realizovani prototip sa mikrofonom i mjernom pločom.

Alarm označava odstupanje od normalnog rada, bez određivanja uzroka promjene. Uticaj govora i drugih zvukova iz prostorije ispituje se posebno.

## 2. Podaci i izbor modela

Globalni model uči se iz 990 normalnih snimaka ventilatora iz skupa DCASE 2026, trajanja približno 10 s. Računar određuje standardizaciju i kovarijansu spektralnih karakteristika. Uređaj računa lokalni centar i pragove iz normalnog rada konkretnog ventilatora.


| Pristup                     | Razlog za ispitivanje i izbor                                                                                                                  |
|-----------------------------|------------------------------------------------------------------------------------------------------------------------------------------------|
| Autoenkoder                 | Polazni neuronski model. Njegova greška rekonstrukcije nije dovoljno razdvajala normalne i anomalne snimke.                                    |
| Log-mel i statistički model | Ispitani su različiti opisi spektra i načini ocjenjivanja, uz ograničena poboljšanja za ventilator.                                            |
| PSD-shape + Ledoit-Wolf     | Izabrani pristup. Finija frekvencijska rezolucija bolje opisuje tonalne komponente zvuka ventilatora, uz mali model pogodan za mikrokontroler. |

Model se uči samo na normalnim snimcima. Anomalni snimci služe za provjeru detekcije, a snimci upotrijebljeni za kalibraciju ne ulaze u ocjenjivanje.

### 3. Obrada signala i implementacija modela

Zvuk se uzorkuje na 16 kHz. Za svaki interval od približno 10 s računa se 96 spektralnih karakteristika koje opisuju raspodjelu snage po frekvenciji. U C-u su napravljene odvojene funkcije za obradu pristiglih blokova zvuka i računanje ocjene. Obrada teče tokom snimanja, pa nije potrebno čuvati cijeli snimak u memoriji.

PCM → Hann prozor i FFT → Welch spektar → PSD-shape



Slika 2. Obrada ilustrativnog signala parametrima projekta. U trećem prikazu izostavljene su trake ispod 28 Hz, među kojima ima praznih traka.

Hann prozor primjenjuje se na segmente od 8192 uzorka, sa pomakom od 4096 uzoraka. Welch postupak usrednjava njihove spektre, a razmak FFT binova iznosi oko 1,95 Hz. Snaga se zatim sažima u 96 logaritamski raspoređenih traka od približno 10 Hz do 4 kHz. Logaritmovanjem i oduzimanjem srednje vrijednosti dobija se PSD-shape, koji naglašava oblik spektra. Uticaj ukupnog nivoa zvuka time se smanjuje, ali se ne uklanja potpuno.

Odstupanje se računa kvadriranom Mahalanobisovom udaljenošću. Ledoit-Wolf postupak daje stabilniju procjenu kovarijanse i omogućava da se pri ocjenjivanju uzmu u obzir odnosi između frekvencijskih traka.

$$s = (z - c)^T P (z - c)$$

| Veličina                     | Kako se dobija                                                        | Uloga u računanju                                |
|------------------------------|-----------------------------------------------------------------------|--------------------------------------------------|
| $z$ — 96 vrijednosti         | Uređaj standardizuje karakteristike novog snimka parametrima sa PC-a. | Opis trenutno snimljenog zvuka.                  |
| $c$ — 96 vrijednosti         | Uređaj računa centar prihvaćenih kalibracionih snimaka.               | Referenca normalnog rada konkretnog ventilatora. |
| $P$ — matrica $96 \times 96$ | Računar procjenjuje inverznu kovarijansu iz normalnih snimaka.        | Određuje značaj odstupanja i veza između traka.  |

Python skripta automatski generiše C tabele sa matricom  $P$  i parametrima standardizacije. One se ugrađuju u program uređaja i zauzimaju 37 632 B. Funkcija za ocjenjivanje koristi te tabele i lokalni centar da izračuna  $s$ . Veća vrijednost označava veće odstupanje od normalnog rada.

### 4. Kalibracija i odluka o alarmu


Protokol GUIDED25 odvajja 10 prozora za lokalni centar, 44 za određivanje pragova i 22 za provjeru normalnog rada sa tim pragovima. Poslije pripreme centar i pragovi ostaju fiksni. Funkcija za vremensku odluku aktivira alarm nakon tri uzastopna pouzdana prozora iznad ulaznog praga. Nepouzdan prozor (HOLD) prekida niz, ali ne poništava već aktivan alarm. Alarm se povlači kada pouzdan prozor dostigne niži izlazni prag ili padne ispod njega.

## 5. Provjera implementacije i rezultati

Za poređenje sa PC-em napravljen je poseban režim provjere. ESP32 snimi 10 s zvuka i pošalje računaru iste PCM uzorke nad kojima je izvršio obradu, zajedno sa svojih 96 izračunatih vrijednosti. Python zatim ponovi obradu i uporedi rezultate. Najveća apsolutna razlika u zabilježenoj provjeri bila je oko  $1,7 \times 10^{-6}$ . Odvojenim testom poređena je i funkcija za računanje ocjene u Pythonu i C-u. Tako je provjereno da prenos algoritma na uređaj daje očekivani numerički rezultat.

| Mjerenje                    | Rezultat i uslovi                                                                                                |
|-----------------------------|------------------------------------------------------------------------------------------------------------------|
| Detekcija na DCASE snimcima | AUC $0,8556 \pm 0,0240$ uz 10 kalibracionih snimaka i 20 razvojnih podjela podataka.                             |
| Računanje na ESP32-S3       | 716–728 ms za spektralne karakteristike i ocjenu po prozoru. U završnim probama nisu prijavljeni gubici uzoraka. |

AUC pokazuje koliko dobro ocjena razdvaja normalne i anomalne snimke. To nije procenat tačnih odluka. Oznaka  $\pm$  predstavlja standardnu devijaciju kroz podjele podataka. Vrijeme računanja ne obuhvata prikupljanje zvuka i čekanje na tri uzastopna prozora potrebna za alarm.



Slika 3. Odstupanje spektralnih karakteristika od lokalnog centra u fizičkoj probi. Pikovi oko 982 Hz i 3 021 Hz odgovaraju dodatnom tonu i trećem harmoniku. Prikazane su medijane po traci, a ne konačna ocjena alarma.

**Proba sa papirićem uz usis.** Promjena zvuka povećala je ocjenu, ali su brojni prozori označeni kao nepouzdana. Alarm je aktiviran u jednom od tri bloka i zadržao se tokom oporavka. Time nisu ispunjeni kriterijumi protokola GUIDED25.

**Proba sa tonom od 1 kHz.** Dodatni ton izazvao je alarm. Naknadna analiza pokazala je da je ton trajao još oko šest minuta poslije oznake oporavka u evidenciji. Zbog toga ta oznaka nije mogla da se koristi kao vrijeme prestanka pobude. Završni povratak u normalu i precizno kašnjenje detekcije nisu potvrđeni.

## 6. Trenutni status

Realizovan je sistem koji sam prikuplja zvuk, kalibriše se i donosi odluku na ESP32-S3. Rezultati na snimcima podržavaju izbor modela za ventilatore, dok su fizičke probe pokazale da treba doraditi postupanje sa nepouzdanim prozorima i povratak iz alarma. Naredni koraci su probe na drugom ventilatoru i mjerenje potrošnje preko INA226, koje još nije završeno. Dosadašnje probe ispituju reakciju na promjenu zvuka, a ne dijagnozu konkretnog kvara.

Izvori: model, obrada u C-u, poređenje sa PC-em, analiza fizičkih proba. Stanje repozitorijuma: 29.09.2026.  
Fotografija: autor projekta.