


Akustička detekcija anomalija na ESP32-S3

Pregled projekta master rada

1. Cilj, hardver i eksperimentalna postavka

Projekat se bavi detekcijom promjena u zvuku ventilatora. Obrada signala i donošenje odluke izvršavaju se na mikrokontroleru ESP32-S3. Poslije kalibracije na normalnom radu, sistem aktivira alarm kada registruje odstupanje kroz više uzastopnih intervala.

Hardver čine ESP32-S3, mikrofoni INMP441 povezan preko I2S veze, taster i mjerna ploča sa INA226. Probe su izvedene u sobi, sa mikrofonom na 40 cm od ventilatora i USB napajanjem od 5 V. Računar vodi probu i bilježi rezultate, a obrada zvuka i odluka izvršavaju se na uređaju.



Slika 1. Realizovani prototip sa mikrofonom i mjernom pločom.

Alarm označava odstupanje od normalnog rada, bez određivanja uzroka promjene. Uticaj govora i drugih zvukova iz prostorije ispituje se posebno.

2. Podaci i izbor modela

Globalni model uči se iz 990 normalnih snimaka ventilatora iz skupa DCASE 2026, trajanja približno 10 s. Računar određuje standardizaciju i kovarijansu spektralnih karakteristika. Uređaj računa lokalni centar i pragove iz normalnog rada konkretnog ventilatora.


Pristup	Razlog za ispitivanje i izbor
Autoenkoder	Polazni neuronski model. Njegova greška rekonstrukcije nije dovoljno razdvajala normalne i anomalne snimke.
Log-mel i statistički model	Ispitani su različiti opisi spektra i načini ocjenjivanja, uz ograničena poboljšanja za ventilator.
PSD-shape + Ledoit-Wolf	Izabrani pristup. Finija frekventijska rezolucija bolje opisuje tonalne komponente zvuka ventilatora, uz mali model pogodan za mikrokontroler.

Model se uči samo na normalnim snimcima. Anomalni snimci služe za provjeru detekcije, a snimci upotrijebljeni za kalibraciju ne ulaze u ocjenjivanje.

3. Obrada signala i implementacija modela

Zvuk se uzorkuje na 16 kHz. Za svaki interval od približno 10 s računa se 96 spektralnih karakteristika koje opisuju raspodjelu snage po frekvenciji. U C-u su napravljene odvojene funkcije za obradu pristiglih blokova zvuka i računanje ocjene. Obrada teče tokom snimanja, pa nije potrebno čuvati cijeli snimak u memoriji.

PCM → Hann prozor i FFT → Welch spektar → PSD-shape



Slika 2. Obrada ilustrativnog signala parametrima projekta. U trećem prikazu izostavljene su trake ispod 28 Hz, među kojima ima praznih traka.

Hann prozor primjenjuje se na segmente od 8192 uzorka, sa pomakom od 4096 uzoraka. Welch postupak računa prosjek spektara dobijenih iz tih segmenata. Razmak FFT binova iznosi oko 1,95 Hz. Zatim se računa prosječna snaga u svakoj od 96 logaritamski raspoređenih frekvencijskih traka, od približno 10 Hz do 4 kHz. Logaritmovanjem i oduzimanjem srednje vrijednosti dobija se PSD-shape, koji naglašava oblik spektra. Uticaj ukupnog nivoa zvuka time se smanjuje, ali se ne uklanja potpuno.

Odstupanje se računa kvadriranjem Mahalanobisovom udaljenošću. Ledoit-Wolf postupak daje stabilniju procjenu kovarijanse i omogućava da se pri ocjenjivanju uzmu u obzir odnosi između frekvencijskih traka.

$$s = (z - c)^T P (z - c)$$

Veličina	Kako se dobija	Uloga u računanju
z — 96 vrijednosti	Uređaj standardizuje karakteristike novog snimka parametrima sa PC-a.	Opis trenutno snimljenog zvuka.
c — 96 vrijednosti	Uređaj računa centar prihvaćenih kalibracionih snimaka.	Referenca normalnog rada konkretnog ventilatora.
P — matrica 96×96	Računar procjenjuje inverznu kovarijansu iz normalnih snimaka.	Određuje značaj odstupanja i veza između traka.

Python skripta automatski generiše C tabele sa matricom P i parametrima standardizacije. One se ugrađuju u program uređaja i zauzimaju 37 632 B. Funkcija za ocjenjivanje koristi te tabele i lokalni centar da izračuna s . Veća vrijednost označava veće odstupanje od normalnog rada.

4. Kalibracija i odluka o alarmu


Protokol GUIDED25 odvaja 10 prozora za lokalni centar, 44 za određivanje pragova i 22 za provjeru normalnog rada sa tim pragovima. Poslije pripreme centar i pragovi ostaju fiksni. Funkcija za vremensku odluku aktivira alarm nakon tri uzastopna pouzdana prozora iznad ulaznog praga. Nepouzdan prozor (HOLD) prekida niz, ali ne poništava već aktivan alarm. Alarm se povlači kada pouzdan prozor dostigne niži izlazni prag ili padne ispod njega.

5. Provjera implementacije i rezultati

U posebnom režimu provjere ESP32 snimi 10 s zvuka i pošalje PC-u iste PCM uzorke i svojih 96 izračunatih vrijednosti. Python ponovi obradu nad tim uzorcima i uporedi rezultate. Najveća apsolutna razlika bila je oko $1,7 \times 10^{-6}$. Posebno je provjereno i slaganje funkcije za ocjenjivanje u Pythonu i C-u.

Mjerenje	Rezultat i uslovi
Detekcija na DCASE snimcima	AUC $0,8556 \pm 0,0240$ uz 10 kalibracionih snimaka i 20 razvojnih podjela podataka.
Računanje na ESP32-S3	716–728 ms za spektralne karakteristike i ocjenu po prozoru. U završnim probama nisu prijavljeni gubici uzoraka.

AUC pokazuje koliko dobro ocjena razdvaja normalne i anomalne snimke. To nije procenat tačnih odluka. Oznaka $\pm$ predstavlja standardnu devijaciju kroz podjele podataka. Vrijeme računanja ne obuhvata prikupljanje zvuka i čekanje na tri uzastopna prozora potrebna za alarm.



Slika 3. Odstupanje spektralnih karakteristika od lokalnog centra u fizičkoj probi. Pikovi oko 982 Hz i 3 021 Hz odgovaraju dodatnom tonu i trećem harmoniku. Prikazane su medijane po traci, a ne konačna ocjena alarma.

Proba sa papirićem uz usis. Alarm je aktiviran u trećem bloku, a nakon uklanjanja papirića uređaj se vratio u normalno stanje. Prema zapažanju autora, mirnije držanje olakšalo je detekciju. U prva dva bloka bilo je više HOLD prozora. Alarm i oporavak jesu potvrđeni, iako cijeli protokol GUIDED25 nije prošao kriterijume.

Proba sa tonom od 1 kHz. Uređaj je uspješno aktivirao alarm i prijavio promjenu koja traje. Prema zapažanju autora tokom završne probe, poslije gašenja tona vratio se u normalno stanje. Taj završni povratak nije potvrđen sačuvanim zapisom, koji potvrđuje aktiviranje alarma.

6. Rezultat projekta i dorada mjerne ploče

Završni firmware uspješno demonstrira lokalnu kalibraciju i detekciju promjene zvuka na ESP32-S3. Alarm je postignut i tonom i papirićem. Ton daje stabilniju pobudu, dok je kod papirića rezultat osjetljiviji na način držanja. Time je potvrđena funkcionalnost detektora u ispitanoj postavci.

Dalji rad je usmjeren na mjernu ploču sa AMS1117 i INA226. Planirani su kratki i pouzdani napojni vodovi, dodavanje kondenzatora uz mikrofona i provjera rada sa spoljašnjim napajanjem od 5 V, bez USB napajanja uređaja. Nakon provjere napona i struje referentnim instrumentima slijede ponovljena mjerenja pri čekanju, kalibraciji i nadzoru. Mjeri se grana ESP32-S3 i mikrofona iza šanta, bez gubitaka regulatora.

Izvori: model, obrada u C-u, poređenje sa PC-em, analiza fizičkih proba. Stanje repozitorijuma: 29.09.2026.
Fotografija: autor projekta.